

Sensor fusion to Estimate the Orientation of a Scale Autonomous Vehicle using the Kalman Filter

Erid Pacheco, Ariel Guerrero and Mario Arzamendia

Abstract— The fusion of different sensors (accelerometer, gyroscope and magnetometer) has been carried out using a Kalman filter in order to obtain an accurate estimation of the orientation of a scale autonomous vehicle. This was used for the correct navigation of the vehicle which participated in the Robocar race competition. Calibration methods have been implemented (for the accelerometer and gyroscope) with a practical approach, so that it can be implemented before the start of the race in real time. The Kalman filter was simulated to determine the influence of the variation of the parameters that intervene in the Kalman filter equations. The response of the instrumentation to the disturbances was improved, which leads to an adequate estimation of the orientation.

Keywords— Kalman filter, sensor fusion.

I. INTRODUCCIÓN

DESDE hace unos años, la industria de los sensores inerciales ha ido creciendo, debido al bajo coste que estos representan, bajo consumo de energía, así como al nivel de miniaturización al que están llegando [1]. En la actualidad, el ámbito de uso de estos sensores es muy amplio, son utilizados en dispositivos tan comunes para las personas como los celulares, sistemas de entretenimiento, sistemas de seguridad automotriz, etc.

Así mismo, los sistemas de medición se están integrando con más sensores, dado que han demostrado una sustancial ante problemas de diversas áreas. A medida que los datos crecen, también lo hace la necesidad de combinar estos datos provenientes de distintos sensores con lo que se puede extraer la información útil que permita la comprensión del entorno.

La fusión de datos es de especial importancia en cualquier aplicación en donde los datos provenientes de distintas fuentes deben ser combinados, fusionados y agrupados para obtener la apropiada calidad de las mediciones de las variables que deben ser procesadas. Mediante la fusión de datos, la información obtenida a partir de la misma resulta igual de confiable que la información obtenida a partir de un equipo patrón, los cuales, si bien es cierto que son precisos, son elevadamente costosos y por lo tanto de difícil acceso.

E. Pacheco está con el Centro de Investigación en Ciencias, Tecnología e Innovación Científica (CICTIA), Universidad Católica “Nuestra Señora de la Asunción” Campus Alto Paraná - Hernandarias, Paraguay (e-mail: erid.pacheco@uc.edu.py).

A. Guerrero está con el Centro de Tecnología de la Información y Comunicación (CTIC), Fundación Parque Tecnológico de Itaipú (FPTI-PY) - Hernandarias, Paraguay (e-mail: ariel.guerrero@pti.org.py).

M. Arzamendia está con el Centro de Innovación Tecnológica (CITEC), Facultad de Ingeniería – Universidad Nacional de Asunción – Asunción, Paraguay (e-mail: marzamendia@ing.una.py).

La fusión de sensores combina lecturas de diferentes fuentes para obtener información con menos incertidumbre que la información obtenida por cada sensor individual. Esto permite aumentar la supresión de ruido y la precisión del sistema de medición. Por este motivo, la implementación del método de fusión de sensores es muy usado en diversos campos como la robótica, sistemas biomédicos, sistemas militares, equipos de monitoreo, sistemas de trasportes, control de procesos, sistemas de información, etc. [2], pues con ello se logra reducir costos y a la vez se logra la precisión deseada.

Para una navegación autónoma, los vehículos son dotados de una gran cantidad de sensores, debido a que el vehículo debe ser capaz de percibir la mayor cantidad de información proveniente del entorno. Los algoritmos de navegación para vehículos autónomos requieren datos precisos de posición y orientación [3], para conseguir esto, se deben usar sensores de alta calidad, que generalmente son costosos y de difícil acceso. Esta precisión requerida, se puede conseguir con la fusión de sensores, en donde los datos provenientes de distintas fuentes son combinados para obtener la apropiada calidad de las mediciones de las variables que deben ser procesadas.

Este trabajo de investigación se desarrolla a partir de la necesidad de obtener estimaciones precisas de la orientación para la navegación de un vehículo autónomo con sensores de bajo costo.

En el presente trabajo, la forma de navegación básica será la inercial, utilizando como sensores que miden aceleración y velocidad angular (acelerómetro y giroscopio), apoyado por el uso de un sensor auxiliar (magnetómetro, que mide el campo magnético), para tener una referencia de orientación absoluta, y de esta manera, evitar errores acumulativos.

El algoritmo utilizado para la fusión de datos es el filtro de Kalman, el entorno de desarrollo utilizado para la fusión de datos es el LabVIEW y es implementado en un dispositivo embebido (Myrio).

II. MODELO DE CORRECCIÓN DE ERRORES DE LOS SENSORES UTILIZADOS

Para los tres sensores (acelerómetro, giroscopio y magnetómetro), los modelos de compensación resultante tienen la forma:

$$z_{output} = M_{a,g,m}(z_{input} - b_{a,g,m}) \quad (1)$$

donde M es una matriz de 3×3 que representa la corrección por

factor de escala y desalineamiento de ejes (para el acelerómetro y giroscopio), para el magnetómetro representa la corrección por hierro suave, y el vector columna b de 3×1 representa el sesgo del sensor (acelerómetro y giroscopio), corrección por hierro duro para el magnetómetro, z_{output} es la salida del sensor calibrado, z_{input} es la salida del sensor sin calibrar, y los subíndices a , g y m indican el sensor del cual provienen las medidas (a para el acelerómetro, g para el giroscopio y m para el magnetómetro).

Para el caso del acelerómetro y giroscopio, las matrices M y b pueden ser determinados por ajuste de mínimos cuadrados o filtro de Kalman de los pares de entrada [3], esto facilita la calibración en tiempo real (online). Para el caso del magnetómetro, usaremos un algoritmo proporcionado en [4] e implementado en MATLAB, cuya calibración se realiza offline.

III. FUSIÓN DE SENSORES

En [5], la fusión de datos se define como: “un proceso de múltiples niveles y fases de detección automática, que tratan con la asociación, correlación, estimación y combinación de datos e información de una o múltiples fuentes para lograr posiciones de refinado, estimaciones de identidad, evaluaciones completas, situaciones de amenazas oportunas a su significado”. Uno de los algoritmos de fusión más populares es el Filtro de Kalman, su concepto y su funcionamiento se detallan en la siguiente sección.

A. Filtro de Kalman

En [6], se presenta su formulación original. Según [7], el filtro de Kalman es un estimador de lo que se llama “un problema cuadrático lineal”, que es un problema de estimar el “estado” instantáneo de un sistema dinámico lineal perturbado por ruido blanco gaussiano, mediante el uso de medidas correlacionadas linealmente con el estado, pero corrompidas por el ruido blanco. El estimador resultante es estadísticamente óptimo con respecto a cualquier función cuadrática de error de estimación. Opera por medio de un mecanismo de predicción y corrección. En esencia, el algoritmo pronostica el nuevo estado a partir de su estimación previa, añadiendo un término de corrección proporcional a la diferencia entre la medición y la predicción [8].

La referencia [8] se tomó como base de estudio para el algoritmo. Se parte del modelo del sistema, que describe la evolución en el tiempo de la cantidad que se quiere estimar. Esto se representa mediante una ecuación en diferencias lineal estocástica de la siguiente forma:

$$x_k = \Phi_{k-1}x_{k-1} + \Gamma u_{k-1} + w_{k-1} \quad (2)$$

donde:

x_k es el vector de estados de dimensión $n \times 1$

Φ_{k-1} es la matriz de transición de estados. Esta matriz relaciona el vector de estados de un tiempo anterior $k-1$ con el vector de estados actual en el tiempo actual k . Su dimensión es $n \times n$.

u_{k-1} entrada conocida del sistema.

Γ matriz que asocia la entrada con el proceso.

w_{k-1} ruido del proceso con media cero y matriz de covarianza Q .

Luego, se describe el modelo de la medición, dada por la siguiente ecuación:

$$z_k = H_k x_k + v_k \quad (3)$$

donde:

z_k es el vector de mediciones de dimensión $r \times 1$.

H_k es la matriz de observación de las mediciones de dimensión $r \times n$. Esta matriz relaciona el vector de estados x_k con el vector de mediciones z_k .

v_k es el ruido del proceso con media cero y matriz de covarianza R .

Para este trabajo, se considera que las matrices Φ_k , H_k y la matriz de covarianza R son constantes, y que la entrada u_k es cero.

Como se mencionó anteriormente, el filtro opera por medio de un mecanismo de predicción-corrección. El $(-)$ en las ecuaciones (4) y (5) indica los valores *a priori* de las variables (antes de que se use la información de la medición) y $(+)$ en las ecuaciones (6) al (7) indica los valores *a posteriori* de las variables (después de que se usa la información de la medición), las ecuaciones correspondientes a cada etapa se presentan a continuación:

Las ecuaciones de predicción o estimación *a priori* son las siguientes:

$$\hat{x}_k(-) = \Phi \hat{x}_{k-1}(+) \quad (4)$$

$$P_k(-) = \Phi P_{k-1}(+) \Phi^T + Q_{k-1} \quad (5)$$

En esta etapa, se proyectan los estados de un instante de tiempo anterior utilizando la matriz de transición de estados (Φ), además, se propaga la incertidumbre de la estimación previa al estado actual utilizando el modelo del sistema y la covarianza de la perturbación aleatoria del proceso (Q_{k-1}).

Las ecuaciones de corrección o de actualización de la medida (también llamado estimación *a posteriori*) están dadas por:

$$\bar{K}_k = P_k(-) H^T (H P_k(-) H^T + R)^{-1} \quad (6)$$

$$\hat{x}_k(+) = \hat{x}_k(-) + \bar{K}_k (z_k - H \hat{x}_k(-)) \quad (7)$$

$$P_k(+) = P_k(-) - \bar{K}_k H P_k(-) \quad (8)$$

Esta etapa del filtro es la encargada de incorporar las nuevas mediciones del proceso, para producir una estimación con la menor varianza; primeramente, se calcula la ganancia de Kalman (6), a partir de la incertidumbre de la predicción de los estados $P_k(-)$ y de la covarianza de la perturbación aleatoria (R), luego se hace una estimación *a posteriori*, en donde se corrige la estimación *a priori* usando el valor de la medición z_k con la ganancia de Kalman \bar{K}_k ; finalmente se actualiza la

incertidumbre asociada a la estimación a posteriori con la ecuación (8).

IV. DISEÑO, SIMULACIÓN E IMPLEMENTACIÓN

A. Diseño de software

El diseño del programa está basado en un patrón de diseño denominado “máquina de estados” el cual consiste en una estructura de casos embebida en un bucle. Esta arquitectura permite ejecutar código diferente en cada iteración del bucle, en función de alguna condición. Resulta útil para nuestra aplicación, debido a que tenemos estados que se deben ejecutar antes de fusionar la información de los sensores, como la calibración de los mismos, que luego ya no se ejecutarán.

El diagrama de transición de estados de la máquina de estados implementada, se muestra en la Fig. 1. Consta de diez estados y de ocho entradas digitales (d4 al d10 y Stop), las entradas digitales d4 al d10 son para ejecutar cada estado de manera individual, la última entrada digital (Stop), es para finalizar la ejecución del programa, cada estado se describe brevemente a continuación.

“Escribir”, solicita los datos a los sensores. “Leer”, lee los datos de cada sensor. “Procesar”, corrige los datos de cada sensor con los modelos presentados en la sección IV-B. “Kalman” (d4), es el estado encargado de realizar la fusión para la estimación de los ángulos de Euler, Pitch (θ), Roll (φ) y Yaw (ψ). “Matrices R” (d5), se encarga de calcular las matrices de covarianza para su uso en el filtro de Kalman.

“Calibrar Giro” (d6), calcula la matriz b_g mediante el método de mínimos cuadrados, para el giroscopio. “Ganancias acc” (d7), calcula la matriz M_a para el acelerómetro, se utilizó el filtro de Kalman para ello. “Bias ax ay” (d8), se encarga del cálculo de las componentes x e y , de la matriz b_a mediante el método de mínimos cuadrados.

“Bias az” (d9), se encarga del cálculo de las componentes z de la matriz b_a mediante el mismo método, este cálculo se realiza en un estado independiente del cálculo de las componentes x e y , debido a que se requiere que el sensor esté en una posición distinta. “Matrices R acc” (d10), calcula la matriz de covarianza R necesaria para la implementación del filtro de Kalman utilizada para hallar la matriz M_a para el acelerómetro.

A. Simulación del filtro de Kalman de una variable

Resulta útil el diseño de una simulación para filtrar ruido de mediciones de una constante, esto, debido a que se pueden manipular las variables que intervienen en las ecuaciones del filtro de Kalman, y así determinar su influencia sobre la estimación resultante, además, se conocen claramente las características del ruido y el valor real de la constante a ser estimada, de esta manera, se puede evaluar el rendimiento, calculando el error cuadrático medio (error RMS) entre el valor real y la estimación.

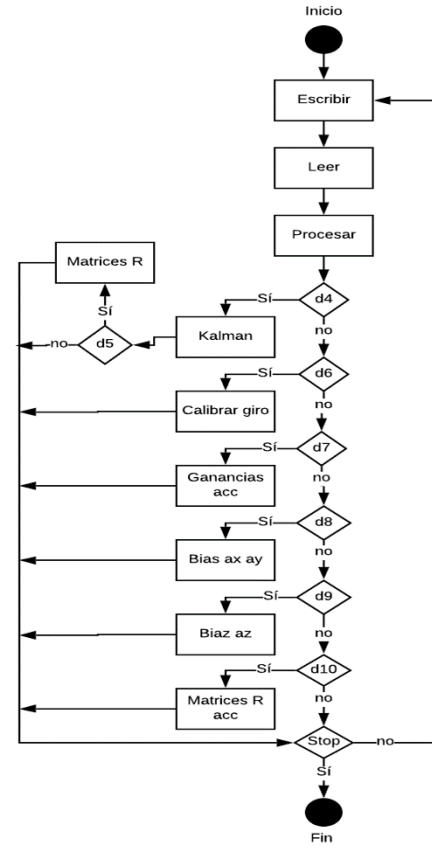


Fig. 1. Diagrama de transición de estados para este proyecto.

Los modelos del proceso y de la medición son los siguientes:

$$x_k = c + w_k \quad (9)$$

$$z_k = c + v_k \quad (10)$$

De esta manera, $\Phi = 1$, suponemos que la constante se mide directamente, por lo tanto, $H = 1$.

Para este caso, tenemos la certeza de que estamos midiendo una constante, por lo tanto, la matriz de covarianza del proceso es cero ($Q = 0$), pero haremos pruebas con distintos valores para ver su efecto sobre el algoritmo. Los valores iniciales del vector de estado \hat{x}_0 y de la matriz de incertidumbre P_0 pueden seleccionarse arbitrariamente. Se sabe por [7], que las ecuaciones (6) al (8) representan un sistema asintóticamente estable, y, por lo tanto, la estimación del estado \hat{x}_k se vuelve independiente de la estimación inicial a medida que k aumenta.

B. Fusión de datos

La estructura básica de la fusión implementada se muestra en la figura 2.

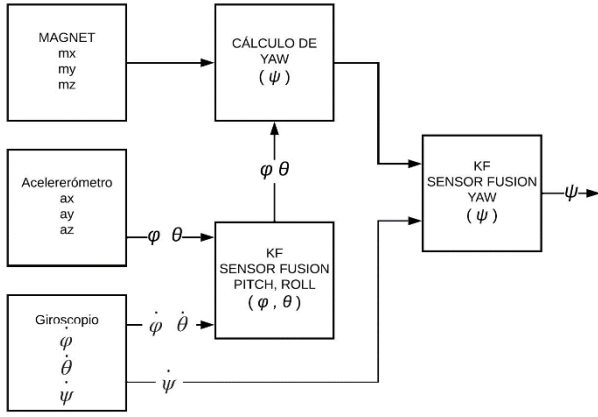


Fig. 2. Estructura de la fusión de datos.

Para el cálculo de los ángulos Pitch (θ) y Roll (ϕ), se fusionan los datos provenientes del acelerómetro y del giroscopio. Primeramente, se calculan los ángulos θ y ϕ a partir de la lectura del acelerómetro, utilizando las relaciones trigonométricas entre los ejes y el vector gravedad. Estas relaciones son válidas cuando el vehículo está en reposo o con velocidad constante, cuando el vehículo sufre aceleraciones, las lecturas no son válidas, es por esto que debemos fusionar estos ángulos con los datos del giroscopio. El cálculo del ángulo Yaw (ψ) es resultado de la fusión del ángulo calculado con el magnetómetro y con el giroscopio. Para el cálculo de Yaw (ψ), con el magnetómetro, se debe proyectar las componentes x e y sobre el plano horizontal, utilizando las matrices de rotación [9], luego, ψ viene dada por:

$$\psi = -\arctan\left(\frac{-m_{yh}}{m_{xh}}\right) \quad (11)$$

donde:

$$\begin{aligned} m_{yh} &= m_y \cos \phi_{KF} - m_z \sin \phi_{KF} \\ m_{xh} &= m_x \cos \theta_{KF} + m_y \sin \phi_{KF} \sin \theta_{KF} + m_z \cos \phi_{KF} \sin \theta_{KF} \end{aligned}$$

Los ángulos θ_{KF} y ϕ_{KF} , son los ángulos calculados a partir de la fusión del acelerómetro con el giroscopio, como se indica en la Fig. 2.

C. Filtro de Kalman para estimar los ángulos Pitch (θ), Roll (ϕ) y Yaw (ψ)

Debido a que el algoritmo para la fusión de datos es similar para los tres ángulos (solamente se diferencian en las matrices Q y R para cada caso), se detallará de manera genérica la fusión, sobre una variable elegida arbitrariamente (α) y su derivada ($\dot{\alpha}$), (que representan el ángulo y la velocidad angular para cada caso).

El modelo del proceso se representa por la siguiente ecuación en diferencias lineal estocástica:

$$\begin{bmatrix} x_k \\ \dot{\alpha}_k \end{bmatrix} = \begin{bmatrix} \phi & \\ 1 & \Delta T \end{bmatrix} \begin{bmatrix} x_{k-1} \\ \dot{\alpha}_{k-1} \end{bmatrix} + w_{k-1} \quad (12)$$

donde w representa el ruido del proceso con media cero y matriz de covarianza Q . Según [3], para la matriz Φ dada en (12), le corresponde la siguiente matriz Q :

$$Q_k = q \begin{bmatrix} \frac{(\Delta T)^3}{3} & \frac{(\Delta T)^2}{2} \\ \frac{(\Delta T)^2}{2} & \Delta T \end{bmatrix} \quad (13)$$

donde q es la covarianza del ruido del proceso en tiempo continuo y ΔT es el tiempo de iteración del algoritmo. El valor de q se ajusta manualmente mediante prueba y error [10].

El vector de medición está dado por:

$$\begin{bmatrix} z_k \\ \dot{\alpha}_k \end{bmatrix} = \begin{bmatrix} H & \\ 1 & 0 \end{bmatrix} \begin{bmatrix} x_k \\ \dot{\alpha}_k \end{bmatrix} + v_k \quad (14)$$

donde v es el ruido de las mediciones con media cero y matriz de covarianza R .

La matriz de covarianza R de las mediciones está dada por:

$$R = \begin{bmatrix} \sigma_\alpha^2 & \sigma_\alpha \sigma_{\dot{\alpha}} \\ \sigma_\alpha \sigma_{\dot{\alpha}} & \sigma_{\dot{\alpha}}^2 \end{bmatrix} \quad (15)$$

donde σ_α^2 y $\sigma_{\dot{\alpha}}^2$ son las varianzas de los ruidos de las mediciones α y $\dot{\alpha}$ respectivamente, $\sigma_\alpha \sigma_{\dot{\alpha}} = \sigma_{\dot{\alpha}} \sigma_\alpha$ son las covarianzas de las mediciones.

Con estas matrices definidas, se puede implementar el filtro de Kalman utilizando las ecuaciones (4) al (8).

V. PRUEBAS Y RESULTADOS

Se realizan las pruebas, con las simulaciones diseñadas anteriormente variando los parámetros, principalmente la matriz de covarianza R , para lograr el comportamiento deseado en la fusión, también se presentan los resultados alcanzados con la fusión para estimar los ángulos deseados.

A. Resultados de la simulación del filtro de Kalman para una variable

En esta sección se presentan los resultados de la implementación de la simulación diseñada en VII-B. El diseño de la interfaz permite que se pueda modificar los parámetros Q , R , x_0 , P_0 y se puede visualizar el error RMS, tanto del filtro, como de las mediciones sin el filtro, de manera a comprobar su efectividad. La interfaz de usuario se muestra en la Fig. 3.

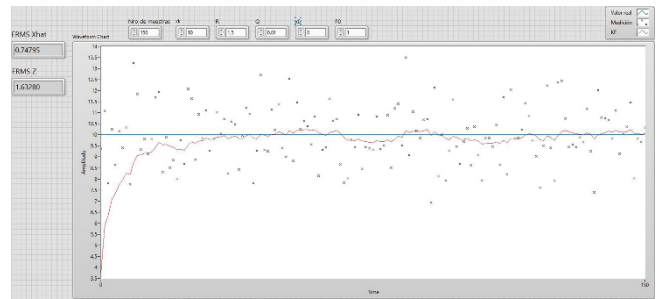


Fig. 3. Interfaz de usuario de la simulación de filtro de Kalman.

En las tablas I y II, podemos ver la influencia de los parámetros Q y R sobre la eficiencia del filtro, manteniendo

constantes las demás variables ($x_k = 10$, $x_0 = 0$, $P_0 = 1$), el número de muestras es 150.

TABLA I
ERRORES RMS CON $Q = \text{CTE}$. Y R VARIABLE

Q	R	ERMS KF	ERMS medición
0.2	0.25	0.14186	0.24519
0.2	0.5	0.21237	0.51645
0.2	1	0.39957	1.09777
0.2	1.25	0.42984	1.29836

TABLA II
ERRORES RMS CON $Q = \text{VARIABLE}$ Y $R = \text{CTE}$.

Q	R	ERMS KF	ERMS medición
0.1	0.5	0.09052	0.42115
0.05	0.5	0.07717	0.51715
0.001	0.5	0.00875	0.49620
0.0005	0.5	0.00701	0.49013

A partir de estos datos, podemos ver la eficiencia del filtro de Kalman, mediante el cual se reduce en todos los casos, el error RMS, como Q representa la varianza de la incertidumbre del proceso, y se sabe que se está midiendo una constante, el filtro resulta más efectivo a medida que $Q \rightarrow 0$, también vemos que al ir aumentando la incertidumbre de la medición R la predicción gana más peso.

B. Resultados de las fusiones Pitch y Roll

Debido a que los resultados para ambos ángulos son similares, se presentará el resultado de la fusión de uno de ellos.

Primeramente, se ha hecho las pruebas con el cálculo de la matriz de covarianza de las mediciones R con el vehículo en reposo.

La R calculada con el vehículo en reposo es la siguiente:

$$R_1 = \begin{bmatrix} 0.0646613 & 0 \\ 0 & 0.108575 \end{bmatrix}$$




Fig. 4. Respuesta del filtro con R_1 ante aceleraciones horizontales.

Con el vehículo sometido a aceleraciones horizontales vemos el error que genera la lectura del ángulo del acelerómetro, al tener una varianza pequeña del error, el filtro da fiabilidad a estas lecturas y no puede ignorar esas aceleraciones. Estos resultados no son satisfactorios, debido a esto, se calcula la matriz de covarianza de las mediciones con el vehículo sometido a aceleraciones horizontales y luego se realiza un ajuste manual mediante prueba y error para conseguir un resultado satisfactorio. La R calculada se muestra a continuación con el resultado en la Fig. 5.

$$R_2 = \begin{bmatrix} 24.5 & 0 \\ 0 & 2.7812 \end{bmatrix}$$




Fig. 5. Respuesta del filtro con R_2 ante aceleraciones horizontales.

El uso de esta R se acerca a lo deseado, aunque no ignora completamente, reduce en gran medida la oscilación de ángulo Roll (ϕ).

C. Fusión Yaw

Una vez obtenidos los ángulos Pitch y Roll, se puede calcular Yaw a partir de la lectura del magnetómetro utilizando la ecuación (11), este ángulo se fusiona con la lectura del giroscopio.

Se procede de manera similar a la fusión para calcular los ángulos Pitch y Roll, primeramente, se calcula la matriz R tomando una cierta cantidad de datos, y calculando la varianza de las mediciones, luego se somete el sensor a disturbios magnéticos (causado con un pequeño imán permanente) para ver el comportamiento de la fusión, finalmente, se realiza un ajuste manual, hasta que alcance el comportamiento deseado.

R calculada con el vehículo sin distorsiones magnéticas:

$$R_1 = \begin{bmatrix} 0.0295689 & 0 \\ 0 & 0.00035017 \end{bmatrix}$$

En la Fig. 6 se puede observar la mejoría que introduce el giroscopio, suavizando la curva, y la componente del magnetómetro contribuye a que no haya errores acumulativos (propias del giroscopio). Pero presenta problemas ante la presencia de distorsiones magnéticas como se puede ver en la Fig. 7.

Queda claro que la distorsión magnética no afecta al giroscopio, en cambio, afecta en gran medida a la lectura del magnetómetro y a salida del filtro de Kalman. Para mejorar estos datos, hacemos un ajuste manual, de manera a darle mayor peso la lectura del giroscopio, aumentando la varianza

de la medición del magnetómetro, de manera a que sea más robusta en ambientes con perturbaciones magnéticas. Con varios ensayos de prueba y error, se llega al siguiente valor de R :

$$R_2 = \begin{bmatrix} 29 & 0 \\ 0 & 2 \end{bmatrix}$$

Los resultados se pueden ver en la Fig. 8. Con esto se consigue un comportamiento adecuado para el entorno de aplicación de la fusión. Dependiendo del entorno de aplicación, se pueden escoger los valores de R adecuados.

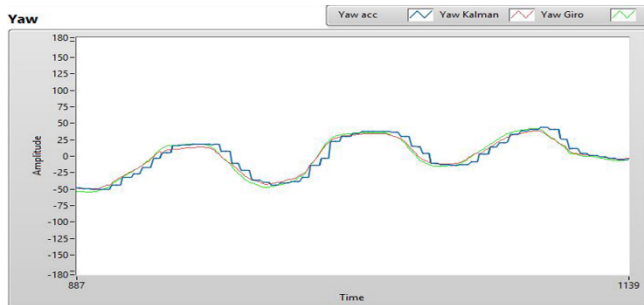


Fig. 6. Respuesta de la fusión Yaw con R_1 sin distorsiones magnéticas.



Fig. 7. Respuesta de la fusión Yaw con R_1 con distorsiones magnéticas.




Fig. 8. Respuesta de la fusión Yaw con R_2 con distorsiones magnéticas.

VI. CONCLUSIONES

Resulta indiscutible la importancia de la fusión de datos de distintos sensores para obtener la calidad adecuada de las mediciones de las variables que deben ser procesadas, conforme a lo que se ha expuesto en este trabajo. Y en efecto,

mediante este procedimiento se logra la utilización de sensores de bajo costo para usarlas mediante la combinación de sus datos y de este modo funcionan como los dispositivos de alta calidad, pero a un costo mucho más bajo.

El análisis del comportamiento del algoritmo mediante simulaciones sirvió para determinar cómo influyen distintos parámetros en la calidad de las estimaciones. Como resultado de la presente investigación se pudo fusionar los sensores (acelerómetro, giroscopio y magnetómetro) de manera correcta y se obtuvo datos más que fueron más robustos a perturbaciones externas, que permitió extraer la información más relevante y exacta posible, a partir de esto se pudo planificar y ejecutar acciones para hacer posible la navegación de un vehículo autónomo

REFERENCIAS

- [1] D. Pozo, N. Sotomayor, J. Rosero y L. Morales, «Medición de ángulos,» *Revista Politécnica*, vol. 33, n° 1, 2014.
- [2] G. A. Gil Vivas, «Desarrollo e implementación de un método de fusión de sensores redundante de bajo costo,» 2017.
- [3] G. Mohinder S. y A. Angus P., *Kalman Filtering: Theory and Practice Using MATLAB*, Fourth ed., Hoboken, New Jersey: JOHN WILEY & SONS, INC., 2015.
- [4] Y. Petrov, «Ellipsoid fit,» 04 12 2015. [En línea]. Available: <https://es.mathworks.com/matlabcentral/fileexchange/24693-ellipsoid-fit>. [Último acceso: 22 10 2018].
- [5] D. Hall y L. James, «An introduction to multisensor data fusion,» *IEEE*, vol. 85, n° 1, pp. 6-23, 1997.
- [6] R. E. Kalman, «A new approach to linear filter and prediction theory,» *J. Basic Eng. D.*, vol. 82, pp. 35-45, 1960.
- [7] G. Mohinder y A. Andrews, *Kalman filtering, Theory and Practice using Matlab*, JohnWiley & Sons, 2008.
- [8] G. Prado, «Técnicas recursivas para estimación dinámica: una introducción matemática al filtro de Kalman,» 2005.
- [9] R. Amezcua Paredes y A. G. Pineda Salgado, «Sistema de referencia inercial: análisis de funcionamiento, fundamentos y evolución,» México D.F., 2012.
- [10] M. Huerta, «Implementación de un sistema de determinación de orientación mediante diseño SOPC en una FPGA para vehículo aéreo no tripulado del tipo quadrotor,» Perú, 2015.
- [11] R. Areny, *Sensores y acondicionadores de señal*, Marcombo, 2004.
- [12] D. P. Vigouroux Cavolina, *Implementación de unidad de mediciones inerciales (IMU) para robótica utilizando filtro de Kalman*, Sartenejas, 2010.
- [13] L. VectorNav Technologies, «VectorNav Technologies LLC,» [En línea]. Available: <https://www.vectornav.com/support/library/magnetometer>. [Último acceso: 28 Marzo 2019].
- [14] Robocar Race, «Robocar Race,» [En línea]. Available: <http://www.robocar.com.br/>. [Último acceso: 2018].